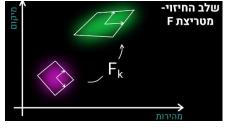
## בסנן קלמן מורחב – EKF

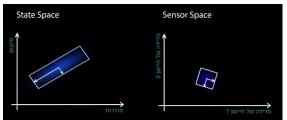
מסנן קלמן רק עובד עם לינאריות. קודם מטריצת F (מטריצת המעבר) והוא חייב להיות התמרה לינארית או במילים אחרות המצב הנוכחי יכול להיות מבוטא רק באמצעות התמרה לינארית מהמצב הקודם. המודל הזה טוב למהירות קבועה ותאוצה קבועה.

? או תנועה במעגל sin, cos או יותר מורכב מו נהיה קצת יותר מורכב

גם מטריצת H המטריצה שמעבירה אותנו ממרכב המצב למרחב החיישן) לינארי. ואם החיישן מודד  $x^2+y^2$  כאן לא נוכל להשתמש בH

> לא H לסיכום מטריצות לסיכום לינארית



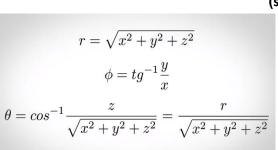


#### סוגי חיישנים



#### **LIDAR**

### נקודות ספריות (sphere)





$$x = r \sin \theta \cos \varphi,$$
  
 $y = r \sin \theta \sin \varphi,$   
 $z = r \cos \theta.$ 

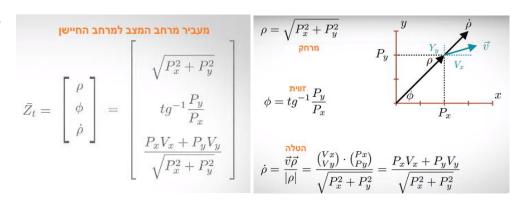


### RADAR חיישן

רק הראדר יכול גם לדעת מהירות של האובייקט שעוקבים אחריו



שים לב שהמשוואת אינן לינאריות

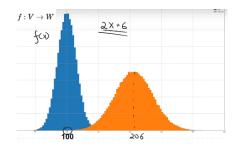


מטריצת - Variance Covariance מטריצת

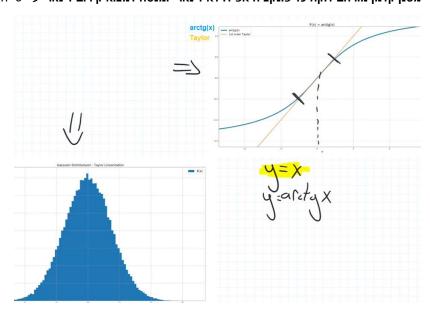
$$R = \begin{bmatrix} \sigma_{\rho}^2 & 0 & 0 \\ 0 & \sigma_{\phi}^2 & 0 \\ 0 & 0 & \sigma_{\dot{\rho}}^2 \end{bmatrix}$$

## <mark>ליניאריזציה</mark>

אם א עדיין M ,  $\sigma^2$  עם Y אם אכניס משתנה M ,  $\sigma^2$  אם אכניס משתנה אני אקבל M , אם אוסיאנית



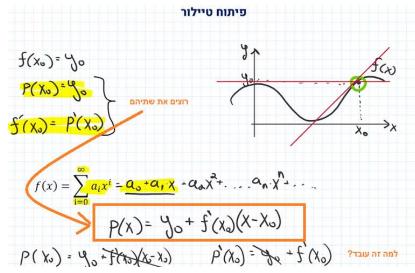
## מסנן קלמן מורחב לוקח כל פונקציה אפילו לא לינארי ומנסה למצוא קירוב לינארי ע"י טיילור



#### פיתוח טיילור

 $x_0$  נותן קירוב מסביב לנקודה

כאן במסנן קלמן נסתכל רק על הקירוב הרשאן והשני או במילים אחרות קירוב מסדר 0 וקירוב מסדר 1



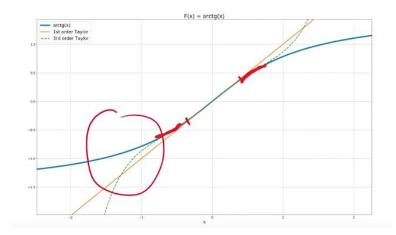
 $y_0$  אנו בעצם רוצים לפתח גם מול פולינום שיתן את שהוא קו האדום מקביל לציר הא וגם מסיביב לנגזרת

להזכירכם, זו הנוסחה שראינו:

$$f(a) + \frac{f'(a)}{1!}(x-a) + \frac{f''(a)}{2!}(x-a)^2 + \frac{f'''(a)}{3!}(x-a)^3 + \cdots,$$

כאשר אנחנו לוקחים רק את <mark>שני האיברים</mark> הראשונים:

$$f(a) + \frac{f'(a)}{1!}(x-a) -$$



כאשר המודל שלנו עובד בצורה דומה ללינארי מסנן קלמן מורחב EKF יתן תוצאות טובות. אבל כאשר הוא יתרחק מהגבולות הלינארים הוא יתחיל לזייף.

הוא טוב עובד טוב בסביבות הלינארים

## . חשבו את שורש 65 לפי פיתוח טיילור מסדר 0,1,2. סביב איזו נקודה הכי נכון לפתח?

הקלידו את התשובות בתיבות הטקסט. דייקו עד לארבע ספרות אחרי הנקודה העשרונית.

$$p_0 = f(64) = \sqrt{64} = 8$$

$$\sqrt{64} + \frac{1}{2\sqrt{64}} = 8.0625$$

$$\sqrt{64} + \frac{1}{2\sqrt{64}} - \frac{1}{2! * 4 * 64^{\frac{3}{2}}} * (65 - 64)^2 = 8.0622$$

#### 2. עכשיו נסו לפתח את הטור סביב הנקודה 16 ולחשב את שורש 65 ותיווכחו כמה אתם רחוקים.

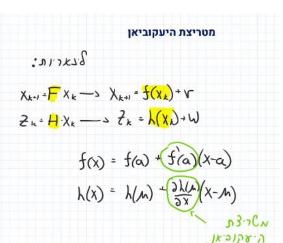
הקלידו את התשובות בתיבות הטקסט. דייקו עד לארבע ספרות אחרי הנקודה העשרונית.

$$p_0 = f(16) = \sqrt{16} = 4$$

$$\sqrt{16} + \frac{1}{2\sqrt{16}} = 10.1250$$

$$\sqrt{16} + \frac{1}{2\sqrt{16}} - \frac{1}{2! * 4 * 16\frac{3}{2}} * (65 - 16)^2 = 5.4355$$

## מטריצת יעקוביאן



 $f(x_k)$  'ניתן לייצג אותה בעזרת פונ' F 'מפני שאנו לא נמצאים בעולם לינארי מט+ F 'עיבג אותה בעזרת פונ' ועוד רעש איז. וכן לגבי מט

הפונ' f(x) נייצג ע"י טור טיילור

בפונ' h נפתח סביב M שהוא הממוצע

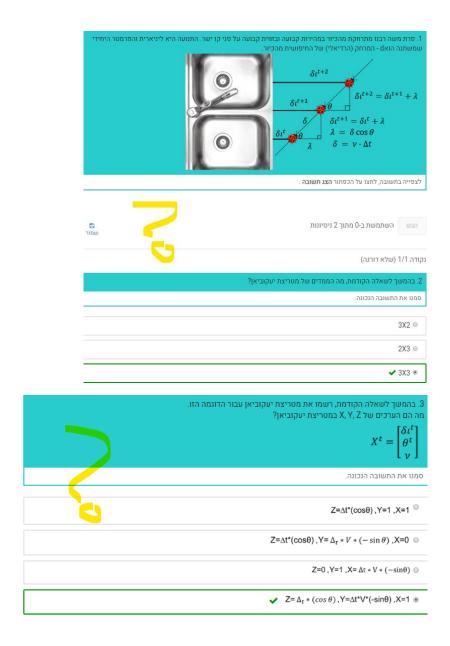
נשים לב שהנגזרת של f שהוא בעיגול ירוק היא דומה לזה שגם ל h נשים לב שהנגזרת של h יש נגזרת שמסומן בירוק שמט' היעקובין. נסמן אותה ב $H_i$  בציור למטה

$$H_{j} = \begin{bmatrix} \frac{\partial h_{0}}{\partial x_{1}} & \frac{\partial h_{1}}{\partial x_{2}} & \frac{\partial h_{1}}{\partial x_{3}} & \cdots & \frac{\partial h_{1}}{\partial x_{n}} \\ \frac{\partial h_{2}}{\partial x_{3}} & \frac{\partial h_{2}}{\partial x_{2}} & \frac{\partial h_{2}}{\partial x_{3}} & \cdots & \frac{\partial h_{2}}{\partial x_{n}} \\ \vdots & \vdots & \ddots & \vdots & \vdots & \vdots \\ \frac{\partial h_{m}}{\partial x_{n}} & \frac{\partial h_{m}}{\partial x_{2}} & \frac{\partial h_{m}}{\partial x_{3}} & \cdots & \frac{\partial h_{m}}{\partial x_{n}} \end{bmatrix}$$

$$H_{j} = \begin{bmatrix} \frac{\partial h_{0}}{\partial x_{2}} & \frac{\partial h_$$

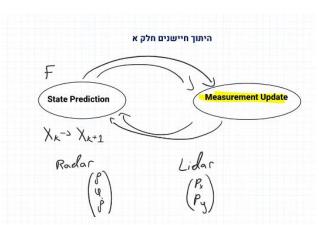
המימד של x H\*x הוא 0 3 x כי הוא מרחב החיישן החיישן 0

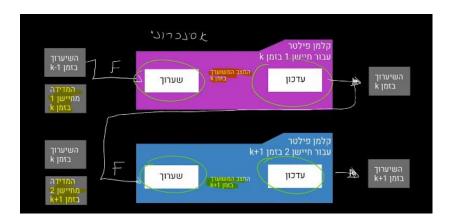
Sensor Space

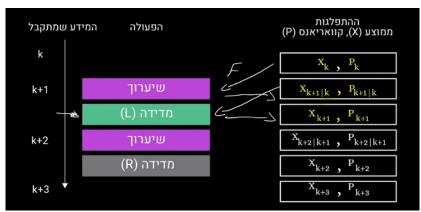


## היתוך חיישנים

ים כן לינארי lidar הראדר הוא לא לינארי לעומת







 $X_{k+3}|k+2=F*X_{k+2}$ 

R: Prediction -> measurment Update

L: Prediction -> measurment Update

L: Prediction -> measurment Update

Xx+3/K+2 = F. Xx+2 (DODANA Se SAINA)

Prediction -> L update -> R update

מה קורה כאשר מקבילים 2 מדידות באותה זמן בזמן k+3 ביחד?

בלי Radar update אני אעשה lidar update בלי מיד אחרי ה באמצע prediction

#### מדידות בזמנים עוקבים

Xx+3/x+2

לא תמיד אנו נקבל את ה $\Delta t$  באותם הפרשי זמנים ולכן נצטרך לעדכן את ביס בא באותטיות. כאן נשנה בא באת באל להיות  $\Delta t - \Delta t_1$  כדי לקבל את ה timestamp המתאים

מט' U – כאשר ידוע לנו מהי התאוצה הקבועה אבל מה קורה כאשר התאוצה לא ידוע לנו?

## The Motion Equations

$$\begin{bmatrix} P_x' \\ P_y' \\ V_x' \\ V_y' \end{bmatrix} = \begin{bmatrix} 1 & 0 & \Delta t & 0 \\ 0 & 1 & 0 & \Delta t \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} P_x \\ P_y \\ V_x \\ V_y \end{bmatrix} + \begin{bmatrix} a_x \frac{\Delta t^2}{2} \\ a_y \frac{\Delta t^2}{2} \\ a_x \Delta t \\ a_y \Delta t \end{bmatrix}$$
 F Matrix (known) U vector

תשובה: אנו נסתכל על U בתור רעש סטוכסטי

שונות של כמה בנ"א הולכים –  $\sigma^2 ax, \sigma^2 ay$  בתאוצה כשהולכים ברחוב

$$\begin{bmatrix} a_x \frac{\Delta t^2}{2} \\ a_y \frac{\Delta t^2}{2} \\ a_x \Delta t \\ a_y \Delta t \end{bmatrix} = \underbrace{\begin{bmatrix} \Delta t^2 & 0 \\ 0 & \Delta t^2 \\ \Delta t & 0 \\ 0 & \Delta t \end{bmatrix}}_{\text{Deterministic}} \underbrace{\begin{bmatrix} a_x \\ a_y \end{bmatrix}}_{\text{Random}} = Ga$$

$$Q = E[v \cdot v^T] = E[Ga \cdot (Ga)^T] = G \cdot \overline{E[aa^T]} \cdot G^T$$

$$Q = G \begin{bmatrix} \sigma_{ax}^2 & 0\\ 0 & \sigma_{ay}^2 \end{bmatrix} G^T$$

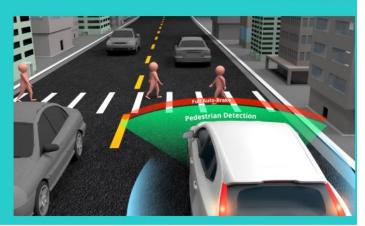
# Process Covariance Matrix

$$Q = GQ_vG = \begin{bmatrix} \frac{\Delta t^4}{4}\sigma_{ax}^2 & 0 & \frac{\Delta t^3}{2}\sigma_{ax}^2 & 0\\ 0 & \frac{\Delta t^4}{4}\sigma_{ay}^2 & 0 & \frac{\Delta t^3}{2}\sigma_{ay}^2\\ \frac{\Delta t^3}{2}\sigma_{ax}^2 & 0 & \Delta t^2\sigma_{ax}^2 & 0\\ 0 & \frac{\Delta t^3}{2}\sigma_{ay}^2 & 0 & \Delta t^2\sigma_{ay}^2 \end{bmatrix}$$

אנו נוסיף את המטריצה Q לוקטור P כשנוסיף את הרעש 1. ביחידה זו ניקח את כל הידע שצברנו עד כה וניישם אותו במשימת תכנות מאתגרת ומעניינת במיוחד. במשימת התכנות ננסה לעקוב אחרי הולך רגל באמצעות חיישני הרדאר וה-LIDAR. שימו לב, אמנם התרגיל עוסק בעקיבה אחרי הולך רגל אבל ניתן להשתמש באותה שיטה בדיוק כדי לעקוב אחרי כלי רכב.

כפי ראינו בסרטון, הנתון היחידי שצריך לספק הוא סטיית התקן של התאוצות בשני הצירים (X-Y). מחקרים מראים שניתן להגדיר את סטיית התקן (סיגמא) כ-2 מטר חלקי שנייה בריבוע.

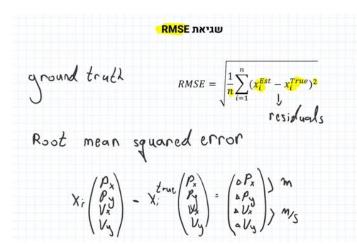
בהנחה שזו סטיית התקן ובהנחה שהתאוצה מתפלגת נורמלית עם ממוצע 🖯 – כמה אנשים נמצאים בין טווח של פלוס ?מינוס 4 מטר לשנייה בריבוע



הקלידו את התשובה בתיבת הטקסט.

אחוז

#### **RSME**



נניח שווקטור המצב המשוערך הוא 
$$x=egin{pmatrix} Px \ Py \ Vx \ Vx \ Yy \end{pmatrix}=egin{pmatrix} 8 \ 12 \ 2 \ 5 \end{pmatrix}$$
 בעוד שהמצב האמיתי נראה כך: 
$$x_{true}=egin{pmatrix} 9 \ 10 \ 2 \ 0 \end{pmatrix}$$
 חשבו את שגיאת ה-RMSE.

הקלידו את התשובה בתיבות הטקסט של המטריצה.



