


מסנן קלמן – מימד 1

Statistics

עקרונות מסנן קלמן



מדידות המכילות חוסר וודאות

השאלה הגדולה של מסנן קלמן: כיצד להשיג שיערוך מדויק מתוך מדידה רועשת?

הערך האמיתי

וקטור המצב (State Vector)

לדוגמה: מיקום, מהירות, תאוצה וכו'. יכול להיות בממדים רבים

שני יתרונות נוספים של מסנן קלמן

1. שיערוך עקיף
לדוגמה: גזירת מהירות ממיקום

2. היתוך חיישנים (Sensor Fusion)
תהליך מתמטי של חיבור מידע מחיישנים שונים, ליצירת שיערוך חדש, מדויק יותר מכל אחד מהם.

Kalman Gain

היחס בין משקל המדידה הנוכחית לבין השיערוך של המצב הקודם.

ככל שקלמן גיין מתקרב ל-1, כך גדל משקל המדידה הנוכחית.

ככל שקלמן גיין מתקרב ל-0, כך גדל משקל השיערוך הקודם.

לא צריך לחשב את ה Kalman Gain כי מסנן קלמן יחשב אותו לבד.


estimate (error) של השיערוך

הגבר קלמן יעלה וירד, יעלה אבל הנטיה היא שבסופו הוא יהיה קטן ואז כאשר יגיע מדידה חדשה לא נתעלם ממה שעשינו עד עתה אלא נכניס אותה דרך ה kg לשיערוך שלנו. בעצם נדע לחבר אותה לשיערוך הקודם

$$KG = \frac{Est}{Est + E_{meas}} \quad 0 \leq KG \leq 1 \quad \text{כאשר}$$

$$EST_t = EST_{t-1} + KG(MEAS - EST_{t-1})$$

$$Est_t = (1 - KG)(Est_{t-1})$$



הטמפרטורה האמיתית היא 72 מעלות. הניחוש הראשוני שלנו הוא 68 מעלות, והטעות הראשונית (Eest) היא 2 מעלות. המדידה הראשונית היא 75 מעלות עם טעות של 4 מעלות לכל כיוון.

1. הכניסו את הנתונים לסט המשוואות וחשבו את ה-ESTt, KG, ו-Eest בטבלה.

מלאו את הטבלה שלפניכם. דייקו עד לשתי ספרות אחרי הנקודה העשרונית.


	MEAS	Emeas	EST	Eest	KG
t	75	4	<div>70.33</div> <div>✓</div> <div>Answer: 70.33</div> <div>70.33</div>	<div>1.33</div> <div>Answer: 1.33</div> <div>1.33</div>	<div>0.33</div> <div>✓</div> <div>Answer: 0.33</div> <div>0.33</div>

$$\begin{aligned}
 E - est &= 2 \\
 meas &= 75 \\
 E - meas &= 4 \\
 Estimate_{t-1} &= 68 \\
 KG &= \frac{E_{est}}{E_{est} + E_{meas}} = \frac{2}{2+4} = \frac{1}{3} \\
 Est_t &= Est_{t-1} + KG(Meas - Est_{t-1}) \\
 &= 68 + \frac{1}{3}(75 - 68) = 70\frac{1}{3}
 \end{aligned}$$

	MEAS	Emeas	EST	Eest	KG	Eest t-1
t-1			<div>68</div> <div>✓</div> <div>68</div>			<div>2</div> <div>✓</div> <div>2</div>
t	75	4	<div>70.33</div> <div>✓</div> <div>70.33</div>	<div>1.33</div> <div>✓</div> <div>1.33</div>	<div>0.33</div> <div>✓</div> <div>0.33</div>	
t+1	71	4	<div>70.50</div> <div>✓</div> <div>70.50</div>	<div>1.00</div> <div>✓</div> <div>1.00</div>	<div>0.25</div> <div>✓</div> <div>0.25</div>	
t+2	70	4	<div>70.4</div> <div>✓</div> <div>70.4</div>	<div>0.8</div> <div>✓</div> <div>0.8</div>	<div>0.2</div> <div>✓</div> <div>0.2</div>	
t+3	74	4	<div>71</div> <div>✓</div> <div>71</div>	<div>0.66</div> <div>✓</div> <div>0.66</div>	<div>0.17</div> <div>✓</div> <div>0.17</div>	

ממוצע, ואריאנס, סטיית תקן

Multi-model – כמה ניחשים



היסטורגרה הוא: בדיד ולכן מצריך הרבה חברים כדי להגיע לרצלוציה גבוה. הוא גם multi-modal ויש לו כמה ניחשים
 מסן קלמן: רציף ו uni-modal מה שיש לו ההסתברות הכי גבוה הוא יבחר (ואין לו כמה התפלגויות גאוסיוניות)

4. קיים מקבץ נתונים בעל ממוצע μ וסטיית תקן σ .
 א. מה יהיה הממוצע החדש, אם לכל אחת מהנקודות ב-DATA יתווסף קבוע מסוים K ?
 ב. מה יהיו ערכי הממוצע μ וסטיית התקן σ החדשים, אם כל אחת מהנקודות תיכפל על ידי אותו קבוע K ?
 הקלידו את התשובות בתיבות הטקסט.

א.

ב. ממוצע: סטיית תקן:

סעיף א' $\mu + K$


סעיף ב' $\mu' = K\mu, \sigma' = K\sigma$

<https://www.youtube.com/watch?v=raoTRsdAc3Y>

Gauss


$\mu = \text{Average}$ - ניחוש הטוב ביותר

$\sigma^2 = \text{variance}$ - חוסר הוודאות ואם היא שואף 0 זה אומר שאין חוסר ודאות ושהמערכת מאוד מדויקת




$$N(\mu_1, \sigma_1^2) = \frac{1}{\sqrt{2\pi\sigma_1^2}} e^{-\frac{(x-\mu_1)^2}{2\sigma_1^2}}$$

הכפלה של גאוסיאנים



$$\sigma_3^2 < \sigma_2^2$$



$$M_1 = 10, \sigma_1^2 = 8 \mid M_2 = 13, \sigma_2^2 = 2$$

$$M_3 = \frac{10 \cdot 2 + 13 \cdot 8}{8 + 2} = 12.4$$

$$\sigma_3^2 = \frac{1}{\left(\frac{1}{8}\right) + \frac{1}{2}} = 1.6$$

1. נתונות שתי התפלגויות גאוסיות: לאחת יש ממוצע 10 ושונות בריבוע של 8 ולאחרת יש ממוצע 13 ושונות בריבוע של 2. מה הממוצע והשונות החדשים של ההכפלה בין שני הגאוסיאנים הללו?

הקלידו את התשובות בתיבות הטקסט. דייקו עד לספרה אחת אחרי הנקודה העשרונית.

הממוצע החדש:

12.4

12.4

תשובה

נכון! כל הכבוד! אלה הן התוצאות הנכונות על פי המשוואות שלמדנו.

השונות בריבוע החדשה:

✓

1.6

$$M_1 = 7, \sigma_1^2 = 5, M_2 = 11, \sigma_2^2 = 4$$

$$\mu_3 = \frac{\mu_1 \cdot \sigma_2^2 + \mu_2 \cdot \sigma_1^2}{\sigma_1^2 + \sigma_2^2}$$

$$M_3 = \frac{7 \cdot 4 + 11 \cdot 5}{4 + 5} = 9.2$$

$$\sigma_3^2 = \frac{1}{\left(\frac{1}{5}\right) + \frac{1}{4}} = 2.22 \text{ ???} = 3.1$$

$$\frac{\sigma_1^2}{\sigma_3^2} = \frac{5}{3.1} = 1.6$$

Thus:

$$P(85 \leq x \leq 115) = \int_{85}^{115} \frac{1}{15\sqrt{2\pi}} e^{-\frac{(x-100)^2}{2 \cdot 15^2}} dx$$

$$P(x > 140) = \int_{140}^{\infty} \frac{1}{15\sqrt{2\pi}} e^{-\frac{(x-100)^2}{2 \cdot 15^2}} dx$$

$$\approx 0.0038 = 0.38\%$$

<https://www.youtube.com/watch?v=pYxNSUDSFH4>

$$likelihood = \frac{1}{15 \cdot \sqrt{2\pi}} \cdot e^{-\frac{(125-100)^2}{2 \cdot 15^2}} = 0.0066$$

2. נתון רובוט אשר נמצא בעולם חד ממדי. מיקום הרובוט ניתן על ידי PDF גאוסית עם ממוצע של 7 מטרים ושונות של 5 מטרים רבוע. ברגע מסוים, חיישן GPS מדווח שהרובוט נמצא דווקא במיקום 11 ולא 7. לחיישן ה-GPS יש חוסר דיוק מובנה המתאפיין בשונות של 4 מטרים. בהינתן נתונים אלו, מהו הניחוש הטוב ביותר של מיקום הרובוט? ומהי השונות החדשה?

הקלידו את התשובות במיבית הטקסט. דייקו עד לספרה אחת אחרי הנקודה העשרונית.

הממוצע החדש:

9.2

9.2

תשובה

נכון! כל הכבוד! בהתאם למשוואות שלמדנו, אלה הן התוצאות הנכונות.

השונות החדשה:

3.1

3. על בסיס המיקום האפריורי הראשון של הרובוט (7,5) - פי כמה עלה דיוק המיקום הנוכחי של הרובוט מאשר לפני התזוזה?

הקלידו את התשובה במיבית הטקסט. דייקו עד לספרה אחת אחרי הנקודה העשרונית.

1. בהינתן ש-IQ מתפלג נורמלית באוכלוסייה עם ממוצע 100 וסטיית תקן של 15, מה הסיכוי (Probability) שאדם אקראי אשר יידגם, יהיה בעל IQ הגבוה מ-125?

הקלידו את התשובה במיבית הטקסט. דייקו עד לשלוש ספרות אחרי הנקודה העשרונית.

שמור

השתמשת ב-0 מתוך 2 ניסיונות

הגש

נקודה 1 אפשרית (שלא דורגה)

2. נניח שמצאנו אדם בעל IQ 125. מהי הסבירות (Likelihood) שהוא הגיע מתוך אותה התפלגות נורמלית שתוארו (ממוצע 100, סטיית תקן 15)?

הקלידו את התשובה במיבית הטקסט. דייקו עד לשלוש ספרות אחרי הנקודה העשרונית.

שמור

השתמשת ב-0 מתוך 2 ניסיונות

הגש

נקודה 1 אפשרית (שלא דורגה)

3. מה הסבירות שהוא הגיע מהתפלגות שונה? (ממוצע 115, סטיית תקן של 20)?


הקלידו את התשובה במיבית הטקסט. דייקו עד לשלוש ספרות אחרי הנקודה העשרונית.

מסנן קלמן בממד אחד

תזוזה אי ודאית (הכפלה)

סטיית תקן של הקבוצה (אוכלוסייה) [עריכת קוד מקור | עריכה]

$$\text{סטיית התקן של הנתונים } x_1, \dots, x_n \text{ היא } \sigma = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2} \text{ כאשר } \bar{x} \text{ הוא הממוצע.}$$



1. מיקום רובוט מתאפיין בהתפלגות נורמלית סביב $X=5$ מטרים עם סטיית תקן של 2 מטרים. הרובוט זז 8 מטרים ימינה. לתזוזה יש רעש גאוסי הניתן למידול כסטיית תקן של 1.7 מטרים.
א. מה המיקום החדש של הרובוט? ומה סטיית התקן החדשה שלו?
ב. לפי חוק ה-68-95-99, מה יהיה הטווח של המיקום החדש ב-95 אחוז מהמקרים?

הקלידו את התשובות במיבות הטקסט. דייקו עד לשתי ספרות אחרי הנקודה העשרונית.

א. ממוצע (במטרים):
 Answer: 13 ✓
 13

ב. טווח מ-
 Answer: 8.24 ✗
 7.76

סטיות תקן (במטרים):
 Answer: 2.62 ✓
 2.62

עד
 Answer: 18.24 ✓
 18.24

(2

$$\sigma_1^2 + \sigma_2^2 = 2^2 + 1.7^2 = \sqrt{6.89} = 2.62 = \sigma_3$$


(3 יש טעות באתר

$$13 - 2.62 * 2 = 7.76$$

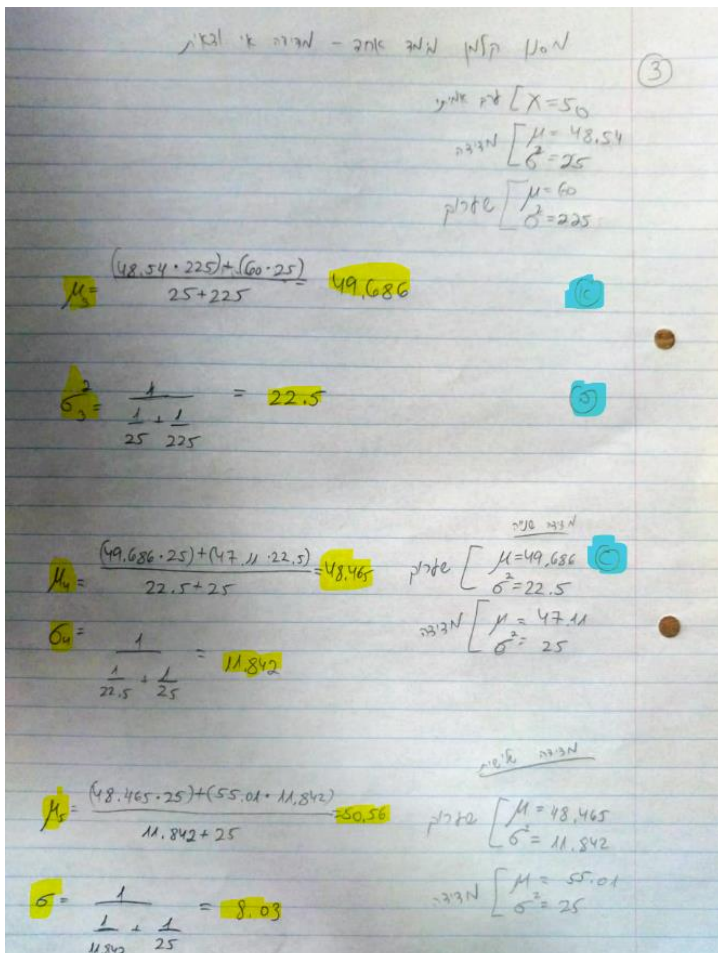
(4

$$13 + 2.62 * 2 = 18.24$$

מדידה אי ודאית (קונבולוציה)



המודל הסטטי הוא בתוך המלבן הכתום. שאר התמונה היא מודל דינמי



מס מדידה	1	2	3	4	5	6	7	8	9	10
תוצאה (מטרים)	48.54	47.11	55.01	55.15	49.89	40.85	46.72	50.05	51.27	49.95

כפי שראינו בפרק, אנחנו מתחילים תמיד מניחוש ראשוני של המצב (STATE) ושל חוסר הוודאות. במקרה שלנו, ההערכה בעין היא שגובה הבניין הוא 60 מטרים.

$$\hat{x}_{0,0} = 60\text{m}$$

נניח שסטיית התקן בהערכת בני אדם היא 15 מטרים.

לכן, השונות היא 225 מטר בריבוע. ($\sigma^2 = 225$) בכתיב משוואות קלמן:

$$p_{0,0} = 225\text{m}^2$$

א. מה יהיה קבוע קלמן ושערוך הגובה החדש לאחר המדידה הראשונה (48.54 מטרים)?

ב. מה יהיה חוסר הוודאות החדש?

ג. חזרו על סעיפים א ו-ב' לגבי המדידה השלישית.

שומר מקום

Answer: 10 ✖ ^{°K}

Answer: 10 ✖ 0.75 ⁻¹

Answer: 10 

סל

מסנן אלפא

$$\hat{x}_{N,N} = \frac{1}{N} (Y_1 + Y_2 + \dots + Y_{N-1} + Y_N) = \frac{1}{N} \sum_{n=1}^N (Y_N)$$

כאשר:

X הוא הערך האמיתי של הטמפרטורה,

Y_n המדידה ה-N מהחיישן,

$\hat{X}_{n,n}$ הוא שערך הטמפרטורה לאחר N מדידות,


$\hat{X}_{n,n-1}$ הוא שערך הטמפרטורה לאחר N-1 מדידות,

$\hat{X}_{n,n+1}$ השערך לאחר N+1 מדידות.

...

$$= \hat{x}_{N,N-1} + \frac{1}{N} (Y_N - \hat{x}_{N,N-1}) =$$

המשמעות היא שהשערך בזמן N תלוי רק במדידת ה-N ובשערך בזמן N-1.



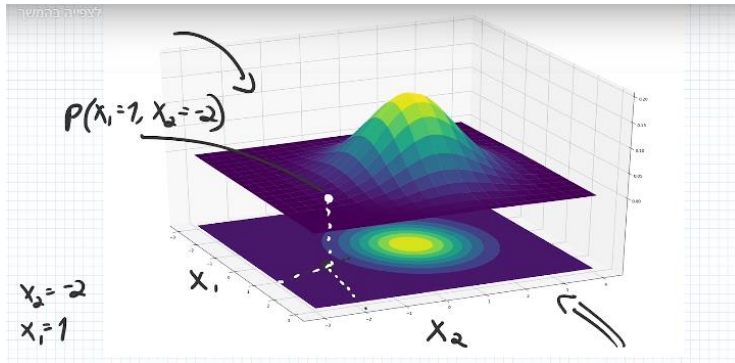
$$\hat{x}_{n,n} = \hat{x}_{n,n-1} + \alpha_n (Y_n - \hat{x}_{n,n-1})$$

בדוגמה שלנו - אלפא הוא המקדם הזה.

סיכום

מסנן קלמן אינו מחייב אותנו לשמור בזיכרון את כל המדידות שעשינו עד כה. למעשה, הוא מאפשר לבחון את המדידה האחרונה ואת השערך האחרון, ועל פי זה לגזור את כל המידע

מסנן קלמן – חלק שני




משוואות התנועה

$$a(t) = a_0$$

$$V(t) = \int_0^t a(t) dt = a_0 \cdot t + V_0$$

$$X(t) = \int_0^t V(t) dt = V_0 \cdot t + \frac{1}{2} \cdot a_0 \cdot t^2 + X_0$$


קורולציה חיובית - קשר ישיר





בגרף א' אין קורולציה בין x_1 ל x_2 .
אם אני יודע איפה אני ב x_1 זה לא
אומר שום דבר היכן אני ב x_2

לאומת זאת בגרף הימני אם אני
יודע שאני למעלה ב x_1 זה אומר שלא
יתכן שאני החלק השאמלי ב x_2 .
בנוסף אם יש קורולציה חיובית - אם
 x_1 עולה אז גם x_2 עולה

גרף א'



קורולציה שלילית - קשר הפוך



$X \text{ dot or } V$ = הוא הנגזרת של המיקום בזמן

X = המיקום

למרות שאני לא יכול למדוד \dot{x} מכיוון שיש
קורולציה לינארית בין x וגם $x \text{ dot}$ אני יכול
להסיק איפה \dot{x}

covariance - זה הקשר בין 2 variance אם
 covariance = 0 זה אומר שאין קשר בניהם

אנלוגיה

רשיון

$$\sigma_{xy} = \frac{\sum_{i=1}^N (\bar{x} - x_i)(\bar{y} - y_i)}{N}$$

מטריצת ה
 variance covariance

$$P = \begin{bmatrix} \sigma_x^2 & \sigma_{xy} \\ \sigma_{yx} & \sigma_y^2 \end{bmatrix}$$

כמה מימדים

$$\mu, \sigma^2 \Rightarrow \underline{\mu}, \underline{\Sigma}$$

מימד אחד

$$\underline{\mu} = \begin{bmatrix} \text{מיקום} \\ \text{מהירות} \end{bmatrix}$$

$$P = \begin{bmatrix} \sigma_x^2 & \sigma_{xy} \\ \sigma_{yx} & \sigma_y^2 \end{bmatrix} = \begin{bmatrix} G_x^2 & G_x G_v \\ G_v G_x & G_v^2 \end{bmatrix}$$

א קבועות
 ב סימטריה

ncalculators.com/statistics/covariance-calculator.htm

ncalculators.com

HOME PRE-ALG

Covariance Calculator

settings sample random add to notes

Dataset set y

0.2, 0.3, 6, 3, 21, 33, 10

comma separated input values

Number of samples = 7

Mean $\mu_X = 14.7857$

Mean $\mu_Y = 10.5$

Covariance $\sigma_{XY} = 188.65$

1. נתונות שתי סדרות המספרים שלהלן:
 $X1 = [2, 3, 4, 10, 22, 55, 7, 5]$
 $X2 = [0.2, 0.3, 6, 3, 21, 33, 10]$
 חשבו את הקווריאנס של 2 המשתנים.

הקלידו את התשובה בתיבת הטקסט.

(המספר הוא סקלר)
 Answer: 3.6 ✖ 188.65

188.65

$$\sigma_{xy} = \frac{\sum_{i=1}^N (\bar{x} - x_i)(\bar{y} - y_i)}{N}$$

הרעיון של משוואות התנועה

מהירות קבועה

$$V(t) = V_0$$

$$X(t) = \int_0^t V(t) dt = V_0 \cdot t + X_0$$

תאוצה קבועה

$$a(t) = a_0$$

$$V(t) = \int_0^t a(t) dt = a_0 \cdot t + V_0$$

$$X(t) = \int_0^t V(t) dt = V_0 \cdot t + \frac{1}{2} \cdot a_0 \cdot t^2 + X_0$$

$$5 * 11 + 14 = 69$$

1. רכב נוסע במהירות קבועה של 5 מטר בשנייה. נניח שהרכב התחיל את הנסיעה שלו ב $X=14$, מה יהיה המיקום שלו לאחר 11 שניות?

הקלידו את התשובה בתיבת הטקסט.

מטר
 69

$$100 = \frac{4.5}{2} * t^2 + 0$$

ה $v_0 t = 0$ כי אין מהירות התחלתי

2. רכב עומד בנקודה $X=0$ ומאיץ בתאוצה של 4.5 מטר בשנייה בריבוע. לאחר כמה זמן יגיע הרכב לנקודה $X=100$?

הקלידו את התשובה בתיבת הטקסט.

שניות
 Answer: 6.6
 6.66

שלב ה - Prediction

שלב ה-PREDICTION - חלק 1

* גאוס במרחב אחת: σ^2, μ

* גאוס בכמה מרחבים: Σ, μ

וקטור המצב
state vector

$\vec{x}_k = \begin{pmatrix} \text{Position} \\ \text{Velocity} \end{pmatrix}$

$\mu = \begin{pmatrix} \mu_1 \\ \mu_2 \\ \mu_3 \\ \mu_4 \\ \vdots \end{pmatrix}$

$\Sigma = \begin{pmatrix} \sigma_1^2 & \sigma_{12} & & \\ \sigma_{21} & \sigma_2^2 & & \\ & & \sigma_3^2 & \\ & & & \ddots & \sigma_n^2 \end{pmatrix}$

$\Sigma_{ij} = \Sigma_{ji}$

$P = \begin{pmatrix} \sigma_{pos}^2 & \sigma_{pos|vel} \\ \sigma_{vel|pos} & \sigma_{vel}^2 \end{pmatrix}$

עד כמה הניחוש שלנו בוקטור המצב מדויק

מט' חוסר ודאות

תנועה במהירות קבועה:

$t=k$ Δt $t=k+1$

x

$pos(k) + \Delta t \cdot V$

$x = x_0 + \Delta t \cdot V$

פונקציית מעבר

$P(k+1) = P(k) + \Delta t \cdot V(k)$

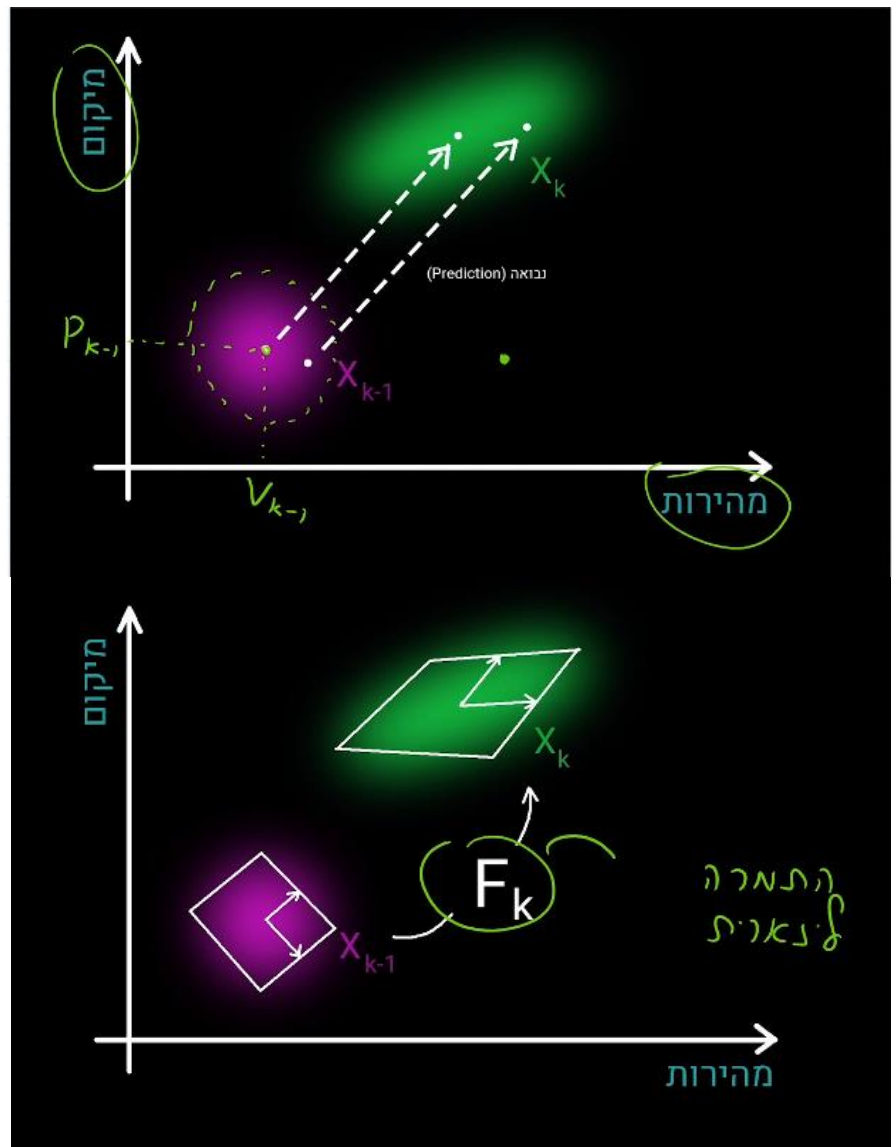
$V(k+1) = V(k)$

$\begin{pmatrix} P \\ V \end{pmatrix}_{k+1} = \begin{pmatrix} 1 & \Delta t \\ 0 & 1 \end{pmatrix} \begin{pmatrix} P \\ V \end{pmatrix}_k$

כל נקודה בסגול שהוא ב x_{k-1} אנו מעבירים אותה ל x_k לשלב הניבוי

אם המודל הוא ליניארי או שבעצם ניתן לכתוב אותו בסט של משוואות אפשר לעשות מעבור במטריצה

במטריצת המעבר F



איך נמצא את P_{k+1} , כלומר מט' חוסר הוודאות הבא?

מט' חוסר ודאות

$$P = \begin{pmatrix} \sigma_{\text{pos}}^2 & \sigma_{\text{pos}} \sigma_{\text{vel}} \\ \sigma_{\text{vel}} \sigma_{\text{pos}} & \sigma_{\text{vel}}^2 \end{pmatrix}$$

עד כמה הניחוש שלנו בוקטור המצב מדויק

$F = A$ מטריצת

ונשתמש בחוק של ה $\text{cov}(Ax)$

מה הקשר ב cov כאן, עדיין לא יודע?

$$\begin{aligned} \underline{x}_{(k+1)} &= F \cdot \underline{x}_{(k)} \\ P_{(k+1)} &= F \cdot P_k \cdot F^T \end{aligned}$$

$$\begin{aligned} \text{cov}(\underline{x}) &= \Sigma \\ \text{cov}(A \cdot \underline{x}) &= A \cdot \Sigma \cdot A^T \end{aligned}$$

משוואות ידועות
(2) רעש סטוכסטי

$$\hat{x}_{(k)} = F \hat{x}_{(k-1)}$$

$$P_{(k)} = F \cdot P_{(k-1)} F^T$$

תאוצה / וטאור
סיבוב / הדרה

כל שני שאנחנו יודעים עליו יכולים להכנס לקטור בקרה \vec{u} ובכך לשפר את הדיוק.

$$P_k = P_{k-1} + \Delta t \cdot V_{k-1} + \frac{1}{2} a_0 \Delta t^2$$

$$V_k = V_{k-1} + \Delta t a_0$$

$$\begin{pmatrix} p \\ v \end{pmatrix}_k = \begin{pmatrix} 1 & \Delta t \\ 0 & 1 \end{pmatrix} \begin{pmatrix} p \\ v \end{pmatrix}_{k-1} + \begin{pmatrix} \frac{1}{2} \Delta t^2 \\ \Delta t \end{pmatrix} a_0$$

↓ ו 2
↓ ו 2

B - מטריצת הבקרה
 \vec{u} - וקטור הבקרה

$$\hat{x}_k = F \hat{x}_{k-1} + B \cdot \vec{u}$$

כאן יש לנו שינויים ידועים כמו תאוצה קבועה.

אין כאן הוספת רעש כי הרעש מתפלג לסביב ה-0.
הרעש יבוא לידי ביטוי במט' P


a_0 הוא וקטור הבקרה. הוקטור של t^2 and t הוא מט' הבקרה B

רעש סטוכסטי - רעשים של יודעים מה הם אבל משפיעים עלינו

כל נקודה לא עוברת ישירות מהסגול אלא היא זזה בעיגול מסביב בעקבות חוסר ודאות

Q - מוסיפה חוסר ודאות בתזוזה (כמו ראינו במסנן קלמן במימד 1)

במה שונה Q מאשר P שהיא $F \cdot P_k \cdot F^T$?
התשובה היא ש P זה חוסר ודאות בוקטור המצב וכאן אנו מוסיפים Q שהוא חוסר ודאות בתזוזה



משוואות הסופיות שלנו:

$$\text{I } \hat{x}_k = F_k \hat{x}_{k-1} + B_k u_k$$

$$\text{II } P_k = F_k P_{k-1} F_k^T + Q_k$$

I In other words, the **new best estimate** is a **prediction** made from **previous best estimate**, plus a **correction** for **known external influences**.

II And the **new uncertainty** is **predicted** from the **old uncertainty**, with some additional uncertainty from the environment.

$$\begin{pmatrix} x + \Delta t * \dot{x} \\ y + \Delta t * \dot{y} \\ \dot{x} \\ \dot{y} \end{pmatrix} = \begin{pmatrix} 1 & 0 & \Delta T & 0 \\ 0 & 1 & 0 & \Delta T \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} X \\ Y \\ \dot{X} \\ \dot{Y} \end{pmatrix}$$

1. הנח מודל מהירות קבועה. איך תיראה מטריצת F כאשר וקטור המצב נראה כך והמערכת נדגמת כל T שניות?

$$\begin{pmatrix} X \\ Y \\ \dot{X} \\ \dot{Y} \end{pmatrix}$$

מה הם הערכים של X, Y, Z במטריצה?

$$\begin{pmatrix} 1 & \boxed{X} & \Delta T & 0 \\ 0 & 1 & 0 & \boxed{Z} \\ 0 & 0 & \boxed{Y} & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

סמנו את התשובה הנכונה.

X=0, Y=1, Z=0 ☐

X=0, Y=ΔT, Z=0 ☐

X=ΔT, Y=1, Z=1 ☐

✓ X=0, Y=1, Z=ΔT ☒

2. הנח מודל עם תאוצה קבועה בשני ממדים, והתאוצה היא חלק מווקטור המצבים. איך תיראה מטריצת F במקרה זה?

$$\begin{pmatrix} X \\ Y \\ \dot{X} \\ \dot{Y} \\ \ddot{X} \\ \ddot{Y} \end{pmatrix}$$

מה הם הערכים של X, Y, Z, W במטריצה?

$$\begin{pmatrix} 1 & 0 & \Delta T & 0 & \frac{1}{2}\Delta T^2 & 0 \\ 0 & \boxed{X} & 0 & \Delta T & 0 & \frac{1}{2}\Delta T^2 \\ 0 & 0 & 1 & 0 & \Delta T & 0 \\ 0 & 0 & 0 & \boxed{Y} & 0 & \boxed{W} \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & \boxed{Z} & 0 & 0 & 0 & 1 \end{pmatrix}$$

סמנו את התשובה הנכונה.

X=0, Y=1, Z=0, W=ΔT ☐

✓ X=1, Y=1, Z=0, W=ΔT ☒

נתונה מערכת התנועה היא בשני ממדים, וקיימת תאוצה בכל ציר. וקטור המצב נראה כך:

$$\begin{pmatrix} X \\ Y \\ \dot{X} \\ \dot{Y} \end{pmatrix}$$

וקטור U נראה כך:

$$\begin{pmatrix} ax \\ ay \end{pmatrix}$$

ב. מה הם הערכים של X, Y, Z במטריצה?

$$\begin{pmatrix} \frac{\Delta T^2}{2} & 0 \\ \boxed{X} & \frac{\Delta T^2}{2} \\ \boxed{Z} & 0 \\ 0 & \boxed{Y} \end{pmatrix}$$

סמנו את התשובה הנכונה.

✓ X=0, Y=ΔT, Z=ΔT ☒

3. נניח שהתאוצה חיצונית לווקטור המצב והיא פועלת רק בציר X.

$$\bar{X} = \begin{pmatrix} X \\ Y \\ \dot{X} \\ \dot{Y} \end{pmatrix}$$

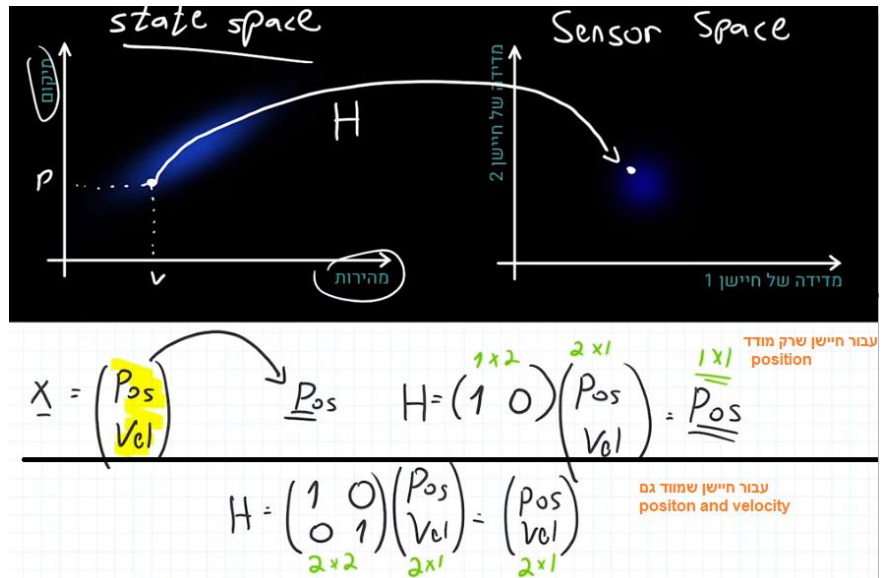
$$\begin{aligned} X_t &= X_{t-1} + \Delta T * \dot{X}_{t-1} + \frac{1}{2} a \Delta T^2 \\ Y_t &= Y_{t-1} + \Delta T * \dot{Y}_{t-1} \end{aligned}$$

$$F = \begin{pmatrix} 1 & 0 & \Delta T & 0 \\ 0 & 1 & 0 & \Delta T \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

$$U = ax$$

שלב ה - Measurement

לא תמיד יש בחיישן שלי את כל הנתונים שיש בוקטור המצב - state vector



ההתמרה H מעביר מ $state\ space$ למרחב החיישן ($sensor\ space$). כמובן שהוא צריך להיות ליניארי.


H הוא בעצם מטריצה

X_k and P_k - מגיעים מהשלב הקודם

$$\begin{aligned} \mu_{expected} &= H_k \cdot X_k \\ \Sigma_{expected} &= H_k \cdot P_k \cdot H_k^T \end{aligned}$$

$$\begin{aligned} \hat{x}_k &= F_k \hat{x}_{k-1} + B_k u_k \\ P_k &= F_k P_{k-1} F_k^T + Q_k \end{aligned}$$


מטריצת R - הרעש של החיישן



הנקודה שמאלית בעיגול הוא מווקטור המצב למרחב החיישן- זה בעצם איפה אני חשבת שאני אמור להיות

הנקודה הימנית בעיגול הוא מדידה במרחב החיישן כאשר Z_k הוא המדידה, R_k הוא הרעש. זה בעצם איפה אני אמור להיות

[See Math Above](#)



Kalman Gain במימד 1

מימד 1

$$\mu' = \mu_0 + \frac{\sigma_0^2(\mu_1 - \mu_0)}{\sigma_0^2 + \sigma_1^2}$$

$$\sigma'^2 = \frac{\sigma_0^2 \sigma_1^2}{\sigma_0^2 + \sigma_1^2}$$

$$\sigma'^2 = \sigma_0^2 - k\sigma_0^2$$

$$\mu' = \mu_0 + k(\mu_1 - \mu_0)$$

$$k = \frac{\sigma_0^2}{\sigma_0^2 + \sigma_1^2}$$

$k \rightarrow 1$
 $\mu \rightarrow \mu_1$
 $k \rightarrow 0$
 $\mu \rightarrow \mu_0$

E est > E mes
 $k \rightarrow 1$ מדידה מדויקת (1)
 שטחיות מצב גלוי (2)
E est < E mes
 $k \rightarrow 0$ מדידה רועלת (1)
 שטחיות מצב גלוי (2)
 Estimate time t not Error Est. $Est_t = Est_{t-1} + k[y_t - Est_{t-1}]$

Kalman Gain ב 2 מימדים

הש (חוסר ודאות) כאן הוא בעצם σ^2 כמו במימד 1 רק כאן הוא ווקטור
 הא (Kalman gain) הוא גם כמו k במימד 1, רק כאן הוא וקטור

$$k = \frac{\sigma_0^2}{\sigma_0^2 + \sigma_1^2}$$

$$K = \Sigma_0(\Sigma_0 + \Sigma_1)^{-1}$$

$$\vec{\mu}' = \vec{\mu}_0 + K(\vec{\mu}_1 - \vec{\mu}_0)$$

$$\Sigma' = \Sigma_0 - K\Sigma_0$$

נעביר למרחב החיטון

המדידה

$$(\mu_1, \Sigma_1) = (\vec{z}_k, R_k)$$

מוצג
חוסר ודאות
ממוצע
רעש במדידה

שטחיות

$$(\mu_0, \Sigma_0) = (H_k \hat{x}_k, H_k P_k H_k^T)$$

מוצג
חוסר ודאות

$$\vec{\mu}' = \vec{\mu}_0 + K(\vec{\mu}_1 - \vec{\mu}_0)$$

$$\Sigma' = \Sigma_0 - K\Sigma_0$$

$$\mu_{expected} = H_k \cdot x_k$$

$$\Sigma_{expected} = H_k \cdot P_k \cdot H_k^T$$

$$\hat{x}_k = F_k \hat{x}_{k-1} + B_k u_k$$

$$P_k = F_k P_{k-1} F_k^T + Q_k$$

$$I \quad H_k \hat{x}'_k = H_k \hat{x}_k + K(\vec{z}_k - H_k \hat{x}_k)$$

$$II \quad H_k P'_k H_k^T = H_k P_k H_k^T - K H_k P_k H_k^T$$

$$III \quad K = \frac{H_k P_k H_k^T}{\Sigma_0 + \Sigma_1} (\Sigma_0 + \Sigma_1)^{-1}$$

נחזיר למרחב המצב

נצמצם את H_k בנוסחא הקודם ונקבל

I $H_k \hat{x}'_k = H_k \hat{x}_k$

II $H_k P'_k H_k^T = H_k P_k H_k^T$

III $K = H_k P_k H_k^T (H_k P_k H_k^T + R_k)^{-1}$

→

שערוך אמרי

1) $\hat{x}'_k = \hat{x}_k + K'(\vec{z}_k - H_k \hat{x}_k)$

2) $P'_k = P_k - K' H_k P_k$

3) $K' = P_k H_k^T (H_k P_k H_k^T + R_k)^{-1}$


כי בעצם אנו רוצים לדעת מה קורה אצלנו לא מעניין מה קורה במרחב החיישן.

משמעות המשוואות האלו

הירוק הוא הprediction שלי

האדום הוא המדידה שלי

הרכב סגלגל – הוא כנראה היכן אני באמת נמצא (כפל גאומטרי בין הירוק והאדום). זה השערוך החדש שבו נשתמש בשערוך הבא



שאלות

$$(X + Y) = \begin{pmatrix} 1 & 1 & 0 \end{pmatrix} \begin{pmatrix} X \\ Y \\ \dot{X} \end{pmatrix}$$

1. נניח שווקטור המצב נראה כך:

$$\begin{pmatrix} X \\ Y \\ \dot{X} \end{pmatrix}$$

ויש לי חיישן היכול למדוד את הנתון $X+Y$ איך תיראה מטריצת H ?

$$H = \begin{pmatrix} \vec{X} & \vec{Y} & \vec{\dot{X}} \end{pmatrix}$$

סמנו את התשובה הנכונה.

☐ $X=0, Y=1, Z=\Delta T$

☐ $X=0, Y=1, Z=0$

☒ $X=1, Y=1, Z=0$

$$\begin{pmatrix} X \\ Y \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{pmatrix} \begin{pmatrix} X \\ Y \\ \dot{X} \\ \dot{Y} \end{pmatrix}$$

2. בהנחה שווקטור המצב מכיל מיקום ומהירות בשני צירים, ויש לי חיישן המספק מדידה עבור מיקום בציר X ומיקום עבור ציר Y - איך תיראה מטריצת H ?

$$\begin{pmatrix} X \\ Y \\ \dot{X} \\ \dot{Y} \end{pmatrix}$$

$$H = \begin{pmatrix} \vec{X} & 0 & \vec{\dot{X}} & 0 \\ 0 & \vec{Y} & 0 & \vec{\dot{Y}} \end{pmatrix}$$

סמנו את התשובה הנכונה.

☐ $X=0, Y=1, Z=1, W=1$

☒ $X=1, Y=1, Z=0, W=0$

$$\hat{x} = \begin{pmatrix} \text{Position}X \\ \text{Position}Y \\ \text{Velocity}X \end{pmatrix}$$

נתונים:

V0X = 280 m/sec X0 = 4000m
Voy = 120 m/sec Yo = 3000m

Observations:

1. X0 = 4000m, Vox = 280 m/sec
2. X1 = 4260m V1x = 282 m/sec
3. X2 = 4550m V2x = 285m/sec

Accelerations:

Ax = 2 m/s*s delta t = 1 sec
Vx = 280 m/s delta X = 25 m

Process Error:

Delta P = 20m
deltaPvx = 5 m/s

Observation Error:

Delta x = 25 m
Delta vx = 6 m/s

- א. וקטור המצב בנקודה 0 נראה כך: $\begin{pmatrix} X_0 \\ V_{x0} \end{pmatrix} = \begin{pmatrix} 4000 \\ 280 \end{pmatrix}$. חשבו את וקטור המצב לאחר שלב ה-Prediction.
- ב. חשבו את מטריצת קלמן.
- ג. חשבו את המיקום המשוערך לפי המדידה.
- ד. חשבו את המיקום הסופי ואת מטריצת P הסופית.
- ה. חזרו על סעיפים 1-4 עבור t=2.

$$P = (I - K \cdot H) \cdot P_{t-1} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} - \begin{pmatrix} \frac{40}{25} & \frac{5}{25} \\ \frac{1}{25} & \frac{3}{25} \end{pmatrix} \cdot \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \cdot \begin{pmatrix} 25 & 5 \\ 5 & 5 \end{pmatrix}$$

$$= \begin{pmatrix} \frac{250}{25} & \frac{10}{25} \\ \frac{10}{25} & \frac{18}{25} \end{pmatrix}$$

המיקום לאחר המדידה יבוא:

$$\hat{X} = F \cdot X + u = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \cdot \begin{pmatrix} 4271 \\ \frac{1404}{5} \end{pmatrix} + \begin{pmatrix} 1 \\ 2 \end{pmatrix} = \begin{pmatrix} 22764 \\ 5 \\ 1414 \\ 5 \end{pmatrix}$$

$$= \begin{pmatrix} 4552.8 \\ 282.8 \end{pmatrix}$$

* לא שרטטתי, אחרי המדידה המיקום של X יבוא $X_2 = 4550, V_{2x} = 285$ (מדידה 3)

מטריצת P הסופית תהיה:

$$P = F \cdot P_{t-1} \cdot F^T = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \cdot \begin{pmatrix} 25 & 5 \\ 5 & 5 \end{pmatrix} \cdot \begin{pmatrix} 1 & 0 \\ 1 & 1 \end{pmatrix} = \begin{pmatrix} 40 & 10 \\ 10 & 5 \end{pmatrix}$$

* הכולל המעלה של המדידה והמיקום של X יבוא 10-1
* סוף היקף של המיקום של X יבוא 10-1 סוף היקף
* המדידה והמיקום של X יבוא 10-1

$$X = \begin{pmatrix} P_{0x} X \\ P_{0y} Y \\ V_{0x} X \end{pmatrix}$$

המיקום והמהירות

$$\begin{pmatrix} P_{0x} X \\ V_{0x} X \end{pmatrix} = \begin{pmatrix} 4000 \\ 280 \end{pmatrix}$$

וקטור המצב לאחר שלב ה-Prediction:

$$\hat{X} = F \cdot X + u = \begin{pmatrix} 1 & \Delta t \\ 0 & 1 \end{pmatrix} \cdot \begin{pmatrix} 4000 \\ 280 \end{pmatrix} + \begin{pmatrix} \frac{1}{2} \Delta t^2 \\ \Delta t \end{pmatrix} \cdot \begin{pmatrix} 2 \\ 2 \end{pmatrix} = \begin{pmatrix} 4281 \\ 282 \end{pmatrix}$$

$\Delta t = 1$
(אחרי 1 שנייה)

$$P = F \cdot P_{t-1} \cdot F^T = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \cdot \begin{pmatrix} 25 & 5 \\ 5 & 5 \end{pmatrix} \cdot \begin{pmatrix} 1 & 0 \\ 1 & 1 \end{pmatrix} = \begin{pmatrix} 25 & 5 \\ 5 & 5 \end{pmatrix}$$

* אין Q כי לא נעו שים
* אין R כי אין מדידה

המדידה של X יבוא 10-1

$$y = z - HX \rightarrow \begin{pmatrix} 4260 \\ 282 \end{pmatrix} - \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \cdot \begin{pmatrix} 4281 \\ 282 \end{pmatrix} = \begin{pmatrix} -21 \\ 0 \end{pmatrix}$$

המדידה של X יבוא 10-1

$$S = H P_{t-1} H^T + R \rightarrow \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \cdot \begin{pmatrix} 25 & 5 \\ 5 & 5 \end{pmatrix} \cdot \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} + \begin{pmatrix} 25 & 0 \\ 0 & 5 \end{pmatrix} = \begin{pmatrix} 50 & 5 \\ 5 & 10 \end{pmatrix}$$

המדידה של X יבוא 10-1

$$K = P_{t-1} \cdot H^T \cdot S^{-1} = \begin{pmatrix} 25 & 5 \\ 5 & 5 \end{pmatrix} \cdot \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \cdot \begin{pmatrix} \frac{1}{50} & -\frac{1}{100} \\ -\frac{1}{100} & \frac{1}{25} \end{pmatrix} = \begin{pmatrix} \frac{1}{2} & -\frac{1}{2} \\ \frac{1}{2} & \frac{1}{2} \end{pmatrix}$$

המדידה של X יבוא 10-1

$$\hat{X} = X_{t-1} + K \cdot y = \begin{pmatrix} 4281 \\ 282 \end{pmatrix} + \begin{pmatrix} \frac{1}{2} & -\frac{1}{2} \\ \frac{1}{2} & \frac{1}{2} \end{pmatrix} \cdot \begin{pmatrix} -21 \\ 0 \end{pmatrix} = \begin{pmatrix} 4271 \\ \frac{1404}{5} \end{pmatrix}$$

$$\Delta x = 20 \text{ m}$$

$$\Delta v_x = 5 \text{ m/sec}$$

$$P_{k-1} = \begin{bmatrix} \Delta x^2 & \Delta x \Delta v \\ \Delta x \Delta v & \Delta v^2 \end{bmatrix} = \begin{bmatrix} 400 & 100 \\ 100 & 25 \end{bmatrix}$$

$$P_{k-1} = \begin{bmatrix} 400 & 0 \\ 0 & 25 \end{bmatrix}$$

① THE PREDICTED STATE

$$X_{kP} = A X_{k-1} + B u_k + w_k$$

$$= \begin{bmatrix} 1 & \Delta t \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x_0 \\ v_{0x} \end{bmatrix} + \begin{bmatrix} \frac{1}{2} \Delta t^2 \\ \Delta t \end{bmatrix} a_{x_0} + 0$$

$$= \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 4000 \\ 280 \end{bmatrix} + \begin{bmatrix} \frac{1}{2} \\ 1 \end{bmatrix} [2]$$

$$= \begin{bmatrix} 4280 \\ 280 \end{bmatrix} + \begin{bmatrix} 1 \\ 2 \end{bmatrix}$$

$$X_{kP} = \begin{bmatrix} 4281 \\ 282 \end{bmatrix}$$

GIVEN: $v_{0x} = 280 \text{ m/sec}$ $x_0 = 4000 \text{ m}$
 $v_{0y} = 120 \text{ m/sec}$ $y_0 = 3000 \text{ m}$

OBSERVATIONS

$x_0 = 4000 \text{ m}$ $v_{0x} = 280 \text{ m/sec}$
 $x_1 = 4260 \text{ m}$ $v_{1x} = 282 \text{ m/sec}$
 $x_2 = 4550 \text{ m}$ $v_{2x} = 285 \text{ m/sec}$
 $x_3 = 4860 \text{ m}$ $v_{3x} = 286 \text{ m/sec}$
 $x_4 = 5110 \text{ m}$ $v_{4x} = 290 \text{ m/sec}$

INITIAL CONDITIONS

$a_x = 2 \text{ m/sec}^2$ $\Delta t = 1 \text{ sec}$
 $v_x = 280 \text{ m/sec}$ $\Delta x = 25 \text{ m}$

PROCESS ERRORS IN PROCESS COVARIANCE MATRIX

$\Delta P_x = 20 \text{ m}$
 $\Delta P_{v_x} = 5 \text{ m/sec}$

OBSERVATION ERRORS

$\Delta x = 25 \text{ m}$
 $\Delta v_x = 6 \text{ m/sec}$

$$P_k = (I - KH) P_{kP}$$

$$P_k = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} - \begin{bmatrix} 0.405 & 0 \\ 0 & 0.410 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 425 & 0 \\ 0 & 25 \end{bmatrix}$$

$$P_k = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} - \begin{bmatrix} 0.405 & 0 \\ 0 & 0.410 \end{bmatrix} \begin{bmatrix} 425 & 0 \\ 0 & 25 \end{bmatrix}$$

$$P_k = \begin{bmatrix} 0.595 & 0 \\ 0 & 0.590 \end{bmatrix} \begin{bmatrix} 425 & 0 \\ 0 & 25 \end{bmatrix}$$

$$P_k = \begin{bmatrix} 253 & 0 \\ 0 & 14.8 \end{bmatrix}$$

$$K = \begin{bmatrix} 0.405 & 0 \\ 0 & 0.410 \end{bmatrix}$$

$$P_{kP} = \begin{bmatrix} 425 & 0 \\ 0 & 25 \end{bmatrix}$$

$$P_{kP} = A P_{k-1} A^T + Q_k$$

$$= \begin{bmatrix} 1 & \Delta t \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 400 & 0 \\ 0 & 25 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ \Delta t & 1 \end{bmatrix} + 0$$

$$= \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 400 & 0 \\ 0 & 25 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}$$

$$= \begin{bmatrix} 400 & 25 \\ 0 & 25 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}$$

$$= \begin{bmatrix} 425 & 25 \\ 25 & 25 \end{bmatrix}$$

$$X_k = X_{kP} + K [Y_k - H X_{kP}]$$

$$= \begin{bmatrix} 4281 \\ 282 \end{bmatrix} + \begin{bmatrix} 0.405 & 0 \\ 0 & 0.410 \end{bmatrix} \left(\begin{bmatrix} 4260 \\ 282 \end{bmatrix} - \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 4281 \\ 282 \end{bmatrix} \right)$$

$$= \begin{bmatrix} 4281 \\ 282 \end{bmatrix} + \begin{bmatrix} 0.405 & 0 \\ 0 & 0.410 \end{bmatrix} \begin{bmatrix} -21 \\ 0 \end{bmatrix}$$

$$= \begin{bmatrix} 4281 \\ 282 \end{bmatrix} + \begin{bmatrix} -8.5 \\ 0 \end{bmatrix}$$

$$X_k = \begin{bmatrix} 4272.5 \\ 282 \end{bmatrix}$$

$$K = \frac{P_{kP} H^T}{H P_{kP} H^T + R}$$

$$= \frac{\begin{bmatrix} 425 & 0 \\ 0 & 25 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}}{\begin{bmatrix} 425 & 0 \\ 0 & 25 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} + \begin{bmatrix} 625 & 0 \\ 0 & 36 \end{bmatrix}}$$

$$= \frac{\begin{bmatrix} 425 & 0 \\ 0 & 25 \end{bmatrix}}{\begin{bmatrix} 425 & 0 \\ 0 & 25 \end{bmatrix} + \begin{bmatrix} 625 & 0 \\ 0 & 36 \end{bmatrix}} = \frac{\begin{bmatrix} 425 & 0 \\ 0 & 25 \end{bmatrix}}{\begin{bmatrix} 1050 & 0 \\ 0 & 61 \end{bmatrix}} = \begin{bmatrix} 0.405 & 0 \\ 0 & 0.410 \end{bmatrix}$$

יישום וסיכום

$$\begin{pmatrix} 1 & 3 & 2 & -5 \end{pmatrix} \begin{pmatrix} X \\ Y \\ V_{elx} \\ V_{ely} \end{pmatrix} = \begin{pmatrix} X & 2V_x & 3Y & -5V_y \end{pmatrix}$$

3. נניח שיש לי חיישן מחזור אשר מודד את הפרמטר הזה: $X+2V_x+3Y-5V_y$.
א. מה הם הממדים של מטריצת H?
סמנו את התשובה הנכונה.

- 4X2
- 2X4
- 4X1
- 1X4

ב. איך תיראה מטריצת H שלול?
הקלידו את התשובה בתיבת הטקסט. הספרה השמאלית מייצגת את השורה במטריצה, והספרה השמאלית - את העמודה שבה.

ב. (✓ 1 , ✓ 3 , ✓ 2 , ✗ 5-)
1 3 2 -5